

# **Econometria Espacial aplicada com R**

Raphael Saldanha; Eduardo Almeida

2023-01-01

# Índice

<b>Apresentação</b>	<b>4</b>
<b>1 Introdução ao R</b>	<b>5</b>
1.1 Instalando o R . . . . .	5
1.2 RStudio . . . . .	5
1.2.1 Que documento é este? . . . . .	6
<b>2 Comandos básicos</b>	<b>7</b>
2.1 Operações matemáticas . . . . .	7
2.1.1 Sua vez . . . . .	8
2.2 Funções . . . . .	8
2.2.1 Sua vez . . . . .	9
2.3 Objetos . . . . .	9
2.3.1 Sua vez . . . . .	10
2.4 Operadores lógicos . . . . .	11
<b>3 Banco de dados</b>	<b>13</b>
3.1 Arquivos CSV . . . . .	13
3.1.1 Sua vez . . . . .	14
<b>4 Estatísticas básicas</b>	<b>15</b>
4.0.1 Sua vez . . . . .	18
<b>5 Análise Exploratória de Dados Espaciais (AED-E)</b>	<b>19</b>
5.1 Leitura do shapefile . . . . .	19
5.2 Atributos do shapefile . . . . .	20
5.3 Mapa . . . . .	21
5.3.1 Sua vez . . . . .	22
<b>6 Matrizes de vizinhos espaciais</b>	<b>24</b>
6.1 Leitura do shapefile . . . . .	24
6.1.1 Matriz queen e rook . . . . .	26
6.1.2 Distância inversa . . . . .	28
6.1.3 Matriz de k-vizinhos espaciais . . . . .	29
6.2 Autocorrelação espacial global . . . . .	32
6.2.1 I de Moran . . . . .	32

6.2.2	C de Geary . . . . .	32
6.2.3	G de Getis-Ord . . . . .	33
6.3	Autocorrelação espacial local . . . . .	34
6.3.1	G de Gettis-Ords . . . . .	34
6.3.2	I de Moran . . . . .	34
6.4	Diagrama de dispersão de Moran . . . . .	35
6.4.1	Sua vez . . . . .	36
6.5	LISA map . . . . .	37
6.5.1	Sua vez . . . . .	38
<b>Referências</b>		<b>40</b>

# Apresentação

Este livro *on-line* apresenta uma introdução a Econometria Espacial aplicada com R. Recomendamos como referência o livro *Econometria Espacial aplicada* (Almeida 2012).

---

Raphael Saldanha é geógrafo, mestre em saúde pública, doutor em Informação e Comunicação em Saúde, *postdoc researcher* no Inria (*Institut national de recherche en sciences et technologies du numérique, France*).

Eduardo Almeida é economista, mestre e doutor em Economia, postdoc pela Escola Superior de Agricultura “Luiz de Queiroz”, professor adjunto da Faculdade de Economia da Universidade Federal de Juiz de Fora (UFJF) desde 2005.

# 1 Introdução ao R

*R* é uma linguagem de programação voltada para análises estatísticas, atualmente mantida pela **R Foundation for Statistical Computing**. Sua origem deriva da linguagem *S* e começou a ser desenvolvida em 1992.

Seu código fonte é aberto e pode ser instalado sem custos em diversos sistemas operacionais, incluindo Windows, Mac e Linux. Além das funções básicas, suas possibilidades de uso são expandidas através da utilização de pacotes, que também são gratuitos. Através dos pacotes, que podem ser criados por qualquer usuário, a linguagem *R* vem ganhando grande espaço na área acadêmica, acompanhando rapidamente o desenvolvimento de diversas áreas do conhecimento.

## 1.1 Instalando o R

Uma cópia do *R* pode ser obtida gratuitamente no site <https://cran.r-project.org/>. Atente para o sistema operacional antes de efetuar o download.

## 1.2 RStudio

Após a instalação do *R*, ele já pode ser usado através de sua interface gráfica padrão. Contudo, é comum a utilização de interfaces de desenvolvimento (IDE - **Integrated Development Environment**) criada por terceiros.

Neste material, iremos utilizar uma IDE chamada *RStudio*. Ela pode ser obtida gratuitamente no site <https://www.rstudio.com/products/RStudio/>.

Após instalar e abrir o RStudio, você verá na tela duas áreas principais. A primeira é chamada de **script** e a segunda de **console**.

A área de **script** é onde digitamos os comandos utilizados no *R*. Após preparar um comando, ele é executado pressionando o botão **run** na interface ou pressionando **Ctrl + r** no teclado. Ao executar um comando, ele será reproduzido na área do console e seu resultado virá logo abaixo.

O **script** é um arquivo de texto que pode ser salvo e reaproveitado posteriormente. É comum encontrarmos em **scripts** do *R* linhas precedidas com o caractere `#`. Este símbolo indica um comentário, ou seja, um texto que não será interpretado como um comando no *R*.

### 1.2.1 Que documento é este?

O **script** é a forma mais tradicional de criar códigos para o *R*, mas ele tem algumas limitações. Por ser apenas um arquivo de texto simples, ele não é capaz de armazenar os resultados produzidos pelo *R*, guardar figuras e ser esteticamente apresentável.

Por estes motivos e na onda da [ciência reproduzível](#), foi criado o **R Notebook**. Um notebook é uma espécie de script versão 2.0, onde é possível escrever comentários com formatação, inserir código do *R* e ver o seu resultado logo abaixo. E a melhor parte: um notebook pode ser exportado para HTML ou PDF facilmente, facilitando o envio de pesquisas feitas com o *R*.

Este arquivo que você está visualizando é um R Notebook. Os asteriscos e alguns símbolos que você está vendo no texto é uma forma de formatação chamada *Markdown*. Por exemplo, dois asteriscos entre uma palavra fazem com que ela fique em *negrito*. Neste [link](#) tem um guia desta **linguagem**.

Para ver como está ficando o seu notebook, clique no botão **Preview**. Uma página irá aparecer com a pré-visualização do seu notebook. Para exportar para HTML ou PDF, use a seta para abaixo ao lado do botão (*Knit to...*).

## 2 Comandos básicos

### 2.1 Operações matemáticas

Os primeiros comandos no R são funções muito básicas para operações matemáticas. A parte verde abaixo é um *chunk* de código R no notebook. Isto indica ao RStudio que esta parte do texto deve ser interpretada como código R e não como texto. Para executar um chunk, pressione Ctrl + Shift + Enter.

```
# Soma  
2+2
```

```
[1] 4
```

```
# Subtração  
4-2
```

```
[1] 2
```

```
# Multiplicação  
2*3
```

```
[1] 6
```

```
# Divisão  
4/2
```

```
[1] 2
```

```
# Exponenciação  
2^3
```

```
[1] 8
```

Se tudo correu bem, você deve ver acima o resultado das operações. Use o preview do notebook para ver como está ficando o resultado do documento.

### 2.1.1 Sua vez

Realize a seguinte operação no R  $((2 + 3(5))/10)^2$ .

```
((2+3*5)/10)^2
```

```
[1] 2.89
```

Resultado correto: 2,89.

## 2.2 Funções

Funções são comandos que apresentam resultados com base em um ou mais argumentos. Teste os exemplos abaixo.

```
# Raiz quadrada  
sqrt(x=9)
```

```
[1] 3
```

```
# Combinação de 10 elementos tomados 2 a 2  
choose(n=10, k=2)
```

```
[1] 45
```

```
# e^x  
exp(2)
```

```
[1] 7.389056
```



```
# Logarítmo natural  
log(1)
```

```
[1] 0
```

### 2.2.1 Sua vez

Calcule a raiz quadrada do logaritmo de 10 no R.

```
sqrt(log(x = 10))
```

```
[1] 1.517427
```

Resultado correto: 1,51.

## 2.3 Objetos

Os resultados de operações simples e funções no R podem ser armazenados na memória para utilização posterior através de objetos.

Na linguagem R, objetos são abstrações na memória que podem conter desde um simples número até complexos bancos de dados. Estude os comandos abaixo.

```
# Criar o objeto x  
x <- 2  
  
# Imprimir o objeto x  
x
```

```
[1] 2
```

```
# Operações com o objeto x  
x^2
```

```
[1] 4
```

```
x+x
```

```
[1] 4
```

```
# Apagar o objeto x
rm(x)

# Criar o vetor y
y <- c(2, 5, 10, 11.3, 12)

# Imprimir o vetor y
y
```

```
[1] 2.0 5.0 10.0 11.3 12.0
```

```
# Elevar o vetor y ao quadrado
y^2
```

```
[1] 4.00 25.00 100.00 127.69 144.00
```

```
# Apagar o vetor y
rm(y)

# Criar o vetor 'notas'
notas <- c(60, 50, 20, 50, 90)

# Ordenar o vetor 'notas'
notas <- sort(notas)

# Imprimir o vetor 'notas'
notas
```

```
[1] 20 50 50 60 90
```

### 2.3.1 Sua vez

Crie um objeto chamado **dados** com os valores {5, 7, 12.7, 13, 15}. Eleve ao quadrado e obtenha o resultado da soma dos valores elevados com a função `sum(x)`.

```
dados <- c(5, 7, 12.7, 13, 15)
sum(dados^2)
```

```
[1] 629.29
```

Resultado correto: 629,29.

## 2.4 Operadores lógicos

Estes operados verificam afirmações de lógica, veja os comandos abaixo.

```
# Igualdade
2 == 2
```

```
[1] TRUE
```

```
2 == 5
```

```
[1] FALSE
```

```
"a" == "a"
```

```
[1] TRUE
```

```
"a" == 'A'
```

```
[1] FALSE
```

```
# Maior
2 > 3
```

```
[1] FALSE
```

```
2 >= 3
```

```
[1] FALSE
```

```
# Menor  
2 < 4
```

```
[1] TRUE
```

```
2 <= 1
```

```
[1] FALSE
```

```
c(1,2,2,4,7,10) < 7
```

```
[1] TRUE TRUE TRUE TRUE FALSE FALSE
```

## 3 Banco de dados

A interface do R não é recomendada para a criação de banco de dados. Como já existem centenas de opções de softwares de qualidade e gratuitos para este fim, os bancos de dados podem ser criados em outros softwares como o Excel e importados posteriormente para o R.

Existem diversos pacotes para ler arquivos de banco de dados no R, como DBF, SAV, Stata e etc. Mas a forma mais segura e recomendada é exportar os dados no formato CSV para ser importados no R.

### 3.1 Arquivos CSV

Para importar este arquivo CSV no R, teste o código abaixo. Se não funcionar, tente trocar “/” por “\”.

```
# Importar o arquivo 'notas.csv'
dados <- read.csv2(file = "data/notas.csv", header = TRUE)
```

Atenção para os nomes das variáveis! Evite a utilização de nomes muito longos, caracteres especiais e acentos.

Após importar um banco de dados, verifique se tudo correu bem com estes comandos.

```
# Estrutura do objeto
str(dados)
```

```
'data.frame':  6 obs. of  3 variables:
 $ id  : int  1 2 3 4 5 6
 $ nome: chr  "Maria" "João" "José" "Maria" ...
 $ nota: num  10 20 32.6 15 40.9 ...
```

```
# Listar os nomes das variáveis
names(dados)
```

```
[1] "id"    "nome"  "nota"
```

```
# Imprimir as seis primeiras linhas
head(dados)
```

```
  id  nome  nota
1  1  Maria 10.00
2  2   João 20.00
3  3   José 32.60
4  4  Maria 15.00
5  5 Gustavo 40.90
6  6 Alfredo 32.86
```

```
# Imprimir as seis últimas linhas
tail(dados)
```

```
  id  nome  nota
1  1  Maria 10.00
2  2   João 20.00
3  3   José 32.60
4  4  Maria 15.00
5  5 Gustavo 40.90
6  6 Alfredo 32.86
```

Para acessar uma variável específica:

```
dados$nota
```

```
[1] 10.00 20.00 32.60 15.00 40.90 32.86
```

### 3.1.1 Sua vez

Importe o mesmo arquivo do exemplo mas com o argumento `header = FALSE`. Execute o comando `str(x)` e veja o que mudou.

```
dados <- read.csv2(file = "data/notas.csv", header = TRUE)
str(dados)
```

```
'data.frame':  6 obs. of  3 variables:
 $ id  : int  1 2 3 4 5 6
 $ nome: chr  "Maria" "João" "José" "Maria" ...
 $ nota: num  10 20 32.6 15 40.9 ...
```

## 4 Estatísticas básicas

Abaixo temos uma lista comandos para obter estatísticas básicas com o R e alguns gráficos.

```
# Importar o arquivo 'notas.csv'
dados <- read.csv2(file = "data/notas.csv", header = TRUE)

# Média
mean(dados$nota)
```

```
[1] 25.22667
```

```
# Mediana
median(dados$nota)
```

```
[1] 26.3
```

```
# Variância
var(dados$nota)
```

```
[1] 144.4083
```

```
# Desvio padrão
sd(dados$nota)
```

```
[1] 12.017
```

```
# Valor máximo
max(dados$nota)
```

```
[1] 40.9
```

```
# Valor mínimo  
min(dados$nota)
```

```
[1] 10
```

```
# Amplitude  
range(dados$nota)
```

```
[1] 10.0 40.9
```

```
# Coeficiente de variação  
sd(dados$nota)/mean(dados$nota)
```

```
[1] 0.476361
```

```
# Quartis  
quantile(dados$nota)
```


0%	25%	50%	75%	100%
10.000	16.250	26.300	32.795	40.900

```
# Sumário  
summary(dados$nota)
```

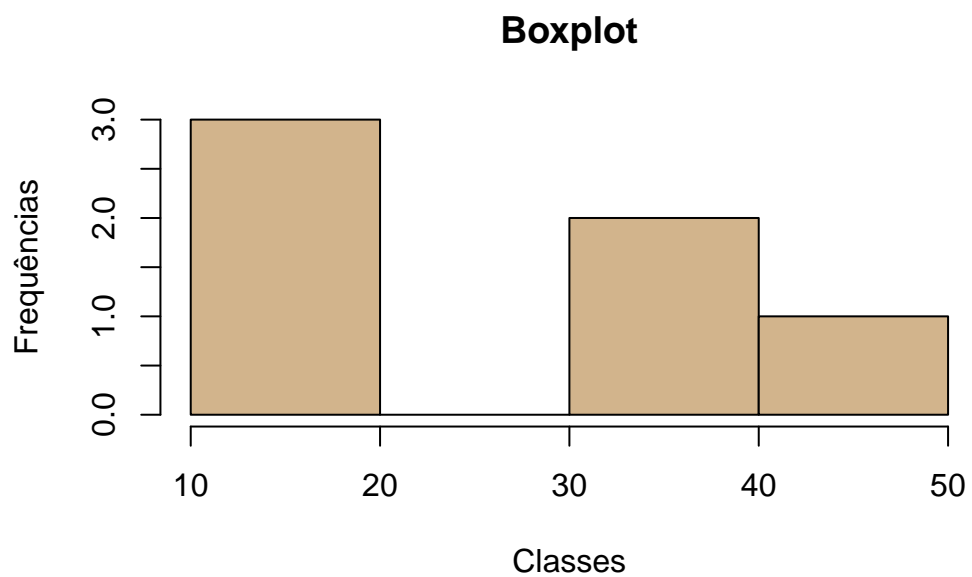
Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
10.00	16.25	26.30	25.23	32.80	40.90

```
# Boxplot  
boxplot(dados$nota)
```





```
# Histograma
hist(dados$nota, main = "Boxplot", xlab = "Classes", ylab = "Frequências", col = "tan")
```



### 4.0.1 Sua vez

O comando `normal <- rnorm(1000)` cria um objeto chamado **normal** com mil valores aleatórios obtidos à partir de uma distribuição normal  $N(0,1)$ . Verifique a média e o desvio padrão deste objeto e crie um histograma.


```
normal <- rnorm(1000, mean = 10, sd = 5)
mean(normal)
```

```
[1] 9.786613
```

```
sd(normal)
```

```
[1] 4.846284
```

```
hist(normal)
```



# 5 Análise Exploratória de Dados Espaciais (AED-E)

## 5.1 Leitura do shapefile

Para a leitura de arquivos **shapefile** no R, precisamos usar alguns pacotes. Após a instalação dos pacotes, use os seguintes comandos.

```
# Pacotes
library(sf)
```

Linking to GEOS 3.10.2, GDAL 3.4.1, PROJ 8.2.1; sf\_use\_s2() is TRUE

```
library(sp)
```

The legacy packages mapproj, rgdal, and rgeos, underpinning the sp package, which was just loaded, will retire in October 2023.

Please refer to R-spatial evolution reports for details, especially <https://r-spatial.org/r/2023/05/15/evolution4.html>.

It may be desirable to make the sf package available;  
package maintainers should consider adding sf to Suggests:.  
The sp package is now running under evolution status 2  
(status 2 uses the sf package in place of rgdal)

```
# Abra o arquivo 'gm10.shp'
fp_mg.shp <- st_read("data/FP_MG.shp", options = "ENCODING=WINDOWS-1252")
```

```
options:          ENCODING=WINDOWS-1252
Reading layer `FP_MG' from data source
  `/home/rfsaldanha/projects/ecoespacial/data/FP_MG.shp' using driver `ESRI Shapefile'
```

Warning in CPL\_read\_ogr(dsn, layer, query, as.character(options), quiet, : GDAL Message 1: organizePolygons() received an unexpected geometry. Either a polygon with interior rings, or a polygon with less than 4 points, or a non-Polygon geometry. Return arguments as a collection.

Simple feature collection with 66 features and 41 fields

Geometry type: POLYGON


Dimension: XY

Bounding box: xmin: -51.06258 ymin: -22.91696 xmax: -39.85724 ymax: -14.23725

CRS: NA

```
fp_mg.shp <- st_make_valid(fp_mg.shp)
fp_mg.shp <- as_Spatial(fp_mg.shp)
# encoding = "UTF-8"
```

```
# Plotar o mapa
plot(fp_mg.shp)
```



## 5.2 Atributos do shapefile

Podemos ver a tabela de atributos do shapefile desta forma.


```
head(fp_mg.shp@data)
```

	CODMIC	NOMMIC	Q	AC	AP	K	R	RP	RNP	DRNP	F	AREA
1	41	Aimorés	134310	60132	60132	1833	363	155	208	25	84	8354.1
2	49	Alfenas	564476	113253	113253	7203	312	273	39	8	1	4998.9
3	14	Almenara	84631	20737	20737	783	383	150	233	15	1	15504.5
4	55	Andrelândia	59164	27764	27764	1154	264	200	64	13	227	5047.3
5	12	Araçuaí	159897	36779	36779	552	315	162	153	15	1	10299.4
6	23	Araxá	495102	160580	160643	7582	645	564	81	6	327	14145.6
	ESCTOT	POPTOT	LP	ACP	KP	ETOTP	DRNPP		FP	RNPP	RPP	
1	347	152658	0.111	0.394	0.012	0.00227	0.00016	0.000550	0.001363	0.001015		
2	229	179366	0.111	0.631	0.040	0.00128	0.00004	0.000006	0.000217	0.001522		
3	384	213342	0.047	0.097	0.004	0.00180	0.00007	0.000005	0.001092	0.000703		
4	191	70783	0.037	0.392	0.016	0.00270	0.00018	0.003207	0.000904	0.002826		
5	327	143468	0.143	0.256	0.004	0.00228	0.00010	0.000007	0.001066	0.001129		
6	182	158275	0.043	1.015	0.048	0.00115	0.00004	0.002066	0.000512	0.003563		
	R_P	QP	X_COORD	Y_COORD	CMICRO	VP	VPP	LA	LM	L		
1	0.002378	0.879810	-41.38876	-19.53116	31041	78349	0.513232	42737	3997	46734		
2	0.001739	3.147062	-46.01852	-21.37551	31049	216064	1.204598	33737	1118	34855		
3	0.001795	0.396692	-40.65978	-16.35385	31014	40164	0.188261	30920	4259	35179		
4	0.003730	0.835850	-44.44562	-21.95045	31055	42360	0.598449	15135	908	16043		
5	0.002196	1.114513	-41.87023	-17.00645	31012	28864	0.201188	45015	7069	52084		
6	0.004075	3.128112	-46.95948	-19.59779	31023	197010	1.244732	23442	1488	24930		
	CO_RUR	NU_RUR	CO_TOT	EER	K_L	VEG	TEMP	PREC	KL			
1	4937	1314045	4402218	0.003757	0.039222	1	4	1	0.0392			
2	6736	2957879	12228817	0.002277	0.206656	2	2	3	0.2067			
3	1431	282421	3363297	0.005067	0.022258	2	5	1	0.0223			
4	1717	498819	2819950	0.003442	0.071932	2	1	4	0.0719			
5	1431	365829	2404595	0.003912	0.010598	3	4	1	0.0106			
6	4357	1476959	14220985	0.002950	0.304132	1	2	4	0.3041			

## 5.3 Mapa

Podemos produzir um mapa colorido com os seguintes comandos.


```
p <- colorRampPalette(c("white", "blue"))(128)
palette(p)
plot(fp_mg.shp, col = fp_mg.shp@data$Q)
```



### 5.3.1 Sua vez

Faça um mapa com a variável AC com a cor vermelha.

```
p <- colorRampPalette(c("yellow", "red"))(128)
palette(p)
plot(fp_mg.shp, col = fp_mg.shp@data$AC)
```



## 6 Matrizes de vizinhos espaciais

### 6.1 Leitura do shapefile

Para a leitura de arquivos **shapefile** no R, precisamos usar alguns pacotes. Após a instalação dos pacotes, use os seguintes comandos.

```
# Pacotes
library(sf)
```

Linking to GEOS 3.10.2, GDAL 3.4.1, PROJ 8.2.1; sf\_use\_s2() is TRUE

```
library(sp)
```

The legacy packages `maptools`, `rgdal`, and `rgeos`, underpinning the `sp` package, which was just loaded, will retire in October 2023.

Please refer to R-spatial evolution reports for details, especially <https://r-spatial.org/r/2023/05/15/evolution4.html>.

It may be desirable to make the `sf` package available; package maintainers should consider adding `sf` to `Suggests`.

The `sp` package is now running under evolution status 2  
(status 2 uses the `sf` package in place of `rgdal`)

```
# Abra o arquivo 'gm10.shp'
fp_mg.shp <- st_read("data/FP_MG.shp", options = "ENCODING=WINDOWS-1252")
```

```
options:          ENCODING=WINDOWS-1252
```

```
Reading layer `FP_MG' from data source
```

```
`/home/rfsaldanha/projects/ecoespacial/data/FP_MG.shp' using driver `ESRI Shapefile'
```


```
Warning in CPL_read_ogr(dsn, layer, query, as.character(options), quiet, : GDAL
Message 1: organizePolygons() received an unexpected geometry. Either a
polygon with interior rings, or a polygon with less than 4 points, or a
non-Polygon geometry. Return arguments as a collection.
```



Simple feature collection with 66 features and 41 fields  
Geometry type: POLYGON  
Dimension: XY  
Bounding box: xmin: -51.06258 ymin: -22.91696 xmax: -39.85724 ymax: -14.23725  
CRS: NA

```
fp_mg.shp <- st_make_valid(fp_mg.shp)
fp_mg.shp <- as_Spatial(fp_mg.shp)

# Plotar o mapa
plot(fp_mg.shp)
```



Para a criação de matrizes de vizinhos espaciais, iremos utilizar o pacote `spdep`.

```
# Pacote
library(spdep)
```

Loading required package: `spData`

To access larger datasets in this package, install the `spDataLarge` package with: ``install.packages('spDataLarge', repos='https://nowosad.github.io/drat/', type='source')``

### 6.1.1 Matriz queen e rook

```
# Matriz queen
w1 <- nb2listw(poly2nb(fp_mg.shp, queen = TRUE))
summary(w1)
```

Characteristics of weights list object:

Neighbour list object:

Number of regions: 66

Number of nonzero links: 336

Percentage nonzero weights: 7.713499

Average number of links: 5.090909

Link number distribution:

```
 2  3  4  5  6  7  8  9
 2  9 12 16 16  8  2  1
```

2 least connected regions:

29 38 with 2 links

1 most connected region:

65 with 9 links

Weights style: W

Weights constants summary:

	n	nn	S0	S1	S2
W 66	4356	66	27.58858	269.8006	

```
# Matriz queen 2ª ordem
w1.2 <- nb2listw(nblag_cumul(nblag(poly2nb(fp_mg.shp, queen = TRUE), maxlag = 2)))

# Matrix queen padronizada na linha
w1.w <- nb2listw(poly2nb(fp_mg.shp, queen=TRUE), style="W")
summary(w1.w)
```

Characteristics of weights list object:

Neighbour list object:

Number of regions: 66

Number of nonzero links: 336

Percentage nonzero weights: 7.713499

Average number of links: 5.090909

Link number distribution:

```

2 3 4 5 6 7 8 9
2 9 12 16 16 8 2 1
2 least connected regions:
29 38 with 2 links
1 most connected region:
65 with 9 links

```

```

Weights style: W
Weights constants summary:
      n   nn S0      S1      S2
W 66 4356 66 27.58858 269.8006

```

```

# Matriz rook
w2 <- nb2listw(poly2nb(fp_mg.shp, queen = FALSE))
summary(w2)

```

```

Characteristics of weights list object:
Neighbour list object:
Number of regions: 66
Number of nonzero links: 332
Percentage nonzero weights: 7.621671
Average number of links: 5.030303
Link number distribution:

```

```

2 3 4 5 6 7 8
2 9 12 18 15 7 3
2 least connected regions:
29 38 with 2 links
3 most connected regions:
12 26 65 with 8 links

```

```

Weights style: W
Weights constants summary:
      n   nn S0      S1      S2
W 66 4356 66 27.82221 269.6778

```

```

# Matriz rook padronizada globalmente
w2.c <- nb2listw(poly2nb(fp_mg.shp, queen = FALSE), style = "C")
summary(w2.c)

```

Characteristics of weights list object:

Neighbour list object:

Number of regions: 66

Number of nonzero links: 332

Percentage nonzero weights: 7.621671

Average number of links: 5.030303

Link number distribution:

2 3 4 5 6 7 8

2 9 12 18 15 7 3

2 least connected regions:

29 38 with 2 links

3 most connected regions:

12 26 65 with 8 links

Weights style: C

Weights constants summary:

	n	nn	S0	S1	S2
C	66	4356	66	26.24096	285.489

### 6.1.2 Distância inversa

```
coords <- coordinates(fp_mg.shp)
nb <- dnearneigh(coords, 0, 1000)
dlist <- nbdists(nb, coords)
dlist <- lapply(dlist, function(x) 1/x^2)
w3 <- nb2listw(nb, glist=dlist)
summary(w3)
```

Characteristics of weights list object:

Neighbour list object:

Number of regions: 66

Number of nonzero links: 4290

Percentage nonzero weights: 98.48485

Average number of links: 65

Link number distribution:

65

66

66 least connected regions:

1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34

66 most connected regions:

1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34

Weights style: W

Weights constants summary:

	n	nn	S0	S1	S2
W 66	4356	66	8.369751	267.6908	

```
# Distância inversa padronizada pelo número de vizinhos
w3.u <- nb2listw(nb, glist=dlist, style="U")
summary(w3.u)
```

Characteristics of weights list object:

Neighbour list object:

Number of regions: 66

Number of nonzero links: 4290

Percentage nonzero weights: 98.48485

Average number of links: 65

Link number distribution:

65

66

66 least connected regions:

1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34

66 most connected regions:

1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34

Weights style: U

Weights constants summary:

	n	nn	S0	S1	S2
U 66	4356	1	0.002368187	0.07316268	

Para ver mais opções, veja a ajuda deste comando: `?nb2listw`

### 6.1.3 Matriz de k-vizinhos espaciais

A escolha do número ideal de  $k$  vizinhos será realizada testando-se vários  $k$  e utilizando-se o que retornou o maior valor para a estatística  $I$  de Moran significativo.

```

# Número de permutações
per <- 999

# Número máximo de k vizinhos testados
kv <- 20

# Nome dos registros
IDs <- row.names(fp_mg.shp@data)

# Criação da tabela que irá receber a estatística I de Moran e significância para cada k t
res.pesos <- data.frame(k=numeric(),i=numeric(),valorp=numeric())

# Início do loop
for(k in 1:kv)
{
  # Armazenando número k atual
  res.pesos[k,1] <- k
  # Calculando o I e significância para o k atual
  moran.k <- moran.mc(fp_mg.shp@data$Q,
                      listw=nb2listw(knn2nb(
                        knearneigh(coords, k=k),
                        row.names=IDs),style="B"),
                      nsim=per)
  # Armazenando o valor I para o k atual
  res.pesos[k,2] <- moran.k$statistic
  # Armazenando o p-value para o k atual
  res.pesos[k,3] <- moran.k$p.value
}

# Ver a tabela de k vizinhos, I de Moran e significância
res.pesos

```

	k	i	valorp
1	1	0.5228074	0.006
2	2	0.3875458	0.005
3	3	0.4531317	0.001
4	4	0.4199339	0.001
5	5	0.3944831	0.001
6	6	0.3595862	0.001
7	7	0.3461349	0.001
8	8	0.3286129	0.001
9	9	0.3064023	0.001

```

10 10 0.3157462 0.001
11 11 0.3028398 0.001
12 12 0.2942354 0.001
13 13 0.2791438 0.001
14 14 0.2620697 0.001
15 15 0.2541920 0.001
16 16 0.2429784 0.001
17 17 0.2320723 0.001
18 18 0.2213339 0.001
19 19 0.2117356 0.001
20 20 0.2017898 0.001

```

```

# Sendo todos significativos, iremos usar o k que retornou o maior valor I
maxi <- which.max(res.pesos[,2])

# Criação da matriz usando o k escolhido
w5 <- nb2listw(knn2nb(knearneigh(coords, k=maxi),row.names=IDs),style="B")
summary(w5)

```

Characteristics of weights list object:

Neighbour list object:

Number of regions: 66

Number of nonzero links: 66

Percentage nonzero weights: 1.515152

Average number of links: 1

Non-symmetric neighbours list

Link number distribution:

1

66

66 least connected regions:

1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34

66 most connected regions:

1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34

Weights style: B

Weights constants summary:

n	nn	S0	S1	S2
---	----	----	----	----

B	66	4356	66	98	308
---	----	------	----	----	-----

## 6.2 Autocorrelação espacial global

### 6.2.1 I de Moran

```
moran.test(fp_mg.shp@data$Q, listw = w5)
```

Moran I test under randomisation

data: fp\_mg.shp@data\$Q  
weights: w5

Moran I statistic standard deviate = 3.8645, p-value = 5.566e-05  
alternative hypothesis: greater  
sample estimates:

Moran I statistic	Expectation	Variance
0.52280745	-0.01538462	0.01939499

```
moran.mc(fp_mg.shp@data$Q, listw = w5, nsim = 999)
```

Monte-Carlo simulation of Moran I

data: fp\_mg.shp@data\$Q  
weights: w5  
number of simulations + 1: 1000

statistic = 0.52281, observed rank = 996, p-value = 0.004  
alternative hypothesis: greater

### 6.2.2 C de Geary

```
geary.test(fp_mg.shp@data$Q, listw = w5)
```

Geary C test under randomisation

data: fp\_mg.shp@data\$Q



weights: w5

Geary C statistic standard deviate = 2.6176, p-value = 0.004428

alternative hypothesis: Expectation greater than statistic

sample estimates:

Geary C statistic	Expectation	Variance
0.46130049	1.00000000	0.04235442

```
geary.mc(fp_mg.shp@data$Q, listw = w5, nsim = 999)
```

Monte-Carlo simulation of Geary C

data: fp\_mg.shp@data\$Q

weights: w5

number of simulations + 1: 1000

statistic = 0.4613, observed rank = 3, p-value = 0.003

alternative hypothesis: greater

### 6.2.3 G de Getis-Ord

```
globalG.test(as.vector(scale(fp_mg.shp@data$Q, center = FALSE)), listw = w5, B1correct = T)
```

Getis-Ord global G statistic

data: as.vector(scale(fp\_mg.shp@data\$Q, center = FALSE))

weights: w5

standard deviate = 3.2113, p-value = 0.0006607

alternative hypothesis: greater

sample estimates:

Global G statistic	Expectation	Variance
3.071155e-02	1.538462e-02	2.277991e-05


## 6.3 Autocorrelação espacial local

### 6.3.1 G de Gettis-Ords

```
lg1 <- localG(fp_mg.shp@data$Q, listw = w5)
summary(lg1)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-0.69900	-0.53552	-0.44190	-0.04454	-0.06779	4.21616

```
hist(lg1)
```



### 6.3.2 I de Moran

```
# Cálculo
lm1 <- localmoran(fp_mg.shp@data$Q, listw = w5)
summary(lm1)
```

Ii	E.Ii	Var.Ii	Z.Ii
Min. : -0.83956	Min. : -2.629e-01	Min. : 0.000197	Min. : -4.1007
1st Qu.: 0.07066	1st Qu.: -4.908e-03	1st Qu.: 0.089934	1st Qu.: 0.2869
Median : 0.20075	Median : -3.384e-03	Median : 0.222559	Median : 0.4695
Mean : 0.52281	Mean : -1.538e-02	Mean : 0.860585	Mean : 0.3957
3rd Qu.: 0.27959	3rd Qu.: -1.365e-03	3rd Qu.: 0.322327	3rd Qu.: 0.5559
Max. : 11.31579	Max. : -2.980e-06	Max. : 12.789972	Max. : 4.2162

Pr(z != E(Ii))


Min. : 0.0000248
1st Qu.: 0.5703228
Median : 0.6347460
Mean : 0.6120352
3rd Qu.: 0.7541930
Max. : 0.9892306

```
# Quantos são significativos?
lm1 <- as.data.frame(lm1)
table(lm1$`Pr(z > 0)` < 0.05)
```

< table of extent 0 >

## 6.4 Diagrama de dispersão de Moran

```
moran.plot(fp_mg.shp@data$Q, listw = w5)
```



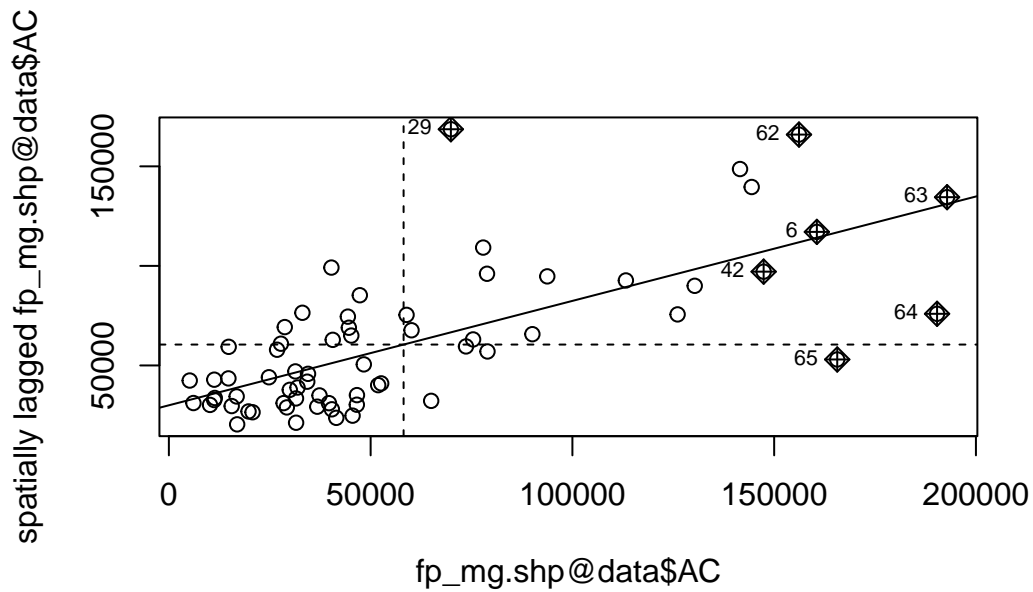
### 6.4.1 Sua vez

Calcule o I de Moran local usando a matriz de vizinhança `w1` para a variável `AC` e verifique quantas regiões são significativas. Depois, faça o diagrama de dispersão.

```
head(localmoran(fp_mg.shp@data$AC, listw = w1))
```

	Ii	E.Ii	Var.Ii	Z.Ii	Pr(z != E(Ii))
1	0.008331081	-2.648711e-05	0.0004165402	0.4094977	0.6821744760
2	0.849842734	-2.085884e-02	0.2071096162	1.9132389	0.0557174771
3	0.529839200	-9.632289e-03	0.1500236654	1.3927995	0.1636804207
4	-0.037360854	-6.355270e-03	0.0781466481	-0.1109136	0.9116848748
5	0.276052134	-3.145335e-03	0.0317953356	1.5657765	0.1174009499
6	2.695852306	-7.209967e-02	0.6784210807	3.3605386	0.0007779067

```
moran.plot(fp_mg.shp@data$AC, listw = w1)
```



## 6.5 LISA map

O R não tem uma função pronta para criar um mapa LISA, então nós criamos abaixo nossa própria função: `lisaplot`. Depois de declarada, uma função pode ser usada repetidamente variando seus argumentos.

Rode o código abaixo.

```
lisaplot <- function(shapefile, values, listw, pval = 0.05){
  require(spdep)

  svalues <- as.vector(scale(values, scale = FALSE))
  lag_svalues <- spdep::lag.listw(listw, svalues)
  locm <- spdep::localmoran(values, listw)
  sig <- rep(0, length(values))

  sig[(svalues >= 0 & lag_svalues >= 0) & (locm[,5] <= pval)] <- 1
  sig[(svalues <= 0 & lag_svalues <= 0) & (locm[,5] <= pval)] <- 2
  sig[(svalues >= 0 & lag_svalues <= 0) & (locm[,5] <= pval)] <- 3
  sig[(svalues <= 0 & lag_svalues >= 0) & (locm[,5] <= pval)] <- 4
  sig[locm[,5] > pval] <- 5
}
```

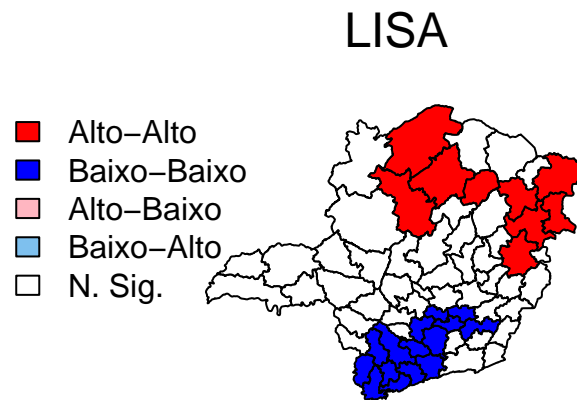
```

breaks <- seq(1, 5, 1)
labels <- c("Alto-Alto", "Baixo-Baixo", "Alto-Baixo", "Baixo-Alto", "N. Sig.")
np <- findInterval(sig, breaks)
colors <- c("red", "blue", "lightpink", "skyblue2", "white")
plot(shapefile, col = colors[np])
mtext("LISA", cex = 1.5, side = 3, line = 1)
legend("topleft", legend = labels, fill = colors, bty = "n")
}

```

E o LISA para a variável TEMP.

```
lisaplot(fp_mg.shp, fp_mg.shp@data$TEMP, w1)
```




### 6.5.1 Sua vez

Faça o LISA para a variável AP com a matriz w1.

```
lisaplot(fp_mg.shp, fp_mg.shp@data$AP, w1)
```

# LISA



## Referências

Almeida, Eduardo. 2012. *Econometria espacial aplicada*. Campinas: Alínea.